RWE 360° · ABRIL 2026

Como Escalar Estudos Clínicos e de Vida Real com Recrutamento Através de Inteligência Artificial

Victor Hugo Ovani Marchetti
Médico · Mestrando em Saúde Pública · LABDAPS/USP · Hapvida

VERSÃO DIGITAL COM LINKS CLICÁVEIS

bit.ly/RWE360pdf

Escaneie o QR code ou acesse o link
para navegar pelas referências com DOI

ABERTURA

A Ciência Avança. O Recrutamento Trava.

Apenas **31–50% dos estudos clínicos atingem suas metas de recrutamento no prazo original** [1]. Mais de 53% precisam de extensões de tempo, e 25% são abandonados prematuramente devido a problemas de recrutamento [2][3]. Para empresas farmacêuticas, esses atrasos custam até **US$ 8 milhões por dia** em receita perdida [4].

Um único centro médico nos EUA identificou 260 estudos encerrados prematuramente (0–1 paciente recrutado) em cinco anos, com custo de quase **US$ 1 milhão** [2].

50%	US$8M	260
dos estudos falham no recrutamento	custo por dia de atraso	estudos encerrados em um único centro

> *E se o maior gargalo da pesquisa clínica não fosse a ciência, mas encontrar as pessoas certas, na hora certa?*

MÓDULO 1 · ENTENDENDO A IA

Duas Forças. Dois Superpoderes.

🧠 IA Generativa

Transforma e **automatiza processos manuais**. LLMs (Large Language Models) leem prontuários inteiros, extraem dados estruturados, geram sumários clínicos — e fazem triagem em linguagem natural. Exemplos: GPT-4, LLaMA, Claude, NER clínico, AI Scribe, sumarização de prontuário.

Alerta: não é para tomar decisão clínica sozinha.

📈 IA Preditiva

Modelos que aprendem padrões em dados longitudinais para antecipar quem vai **desenvolver uma condição, responder a um tratamento ou abandonar** um estudo. O coração da medicina de precisão.

Conexão com medicina de precisão: Modelos preditivos integram dados ômicos, wearables e prontuários longitudinais — o modelo preditivo de amanhã vai saber que um paciente é candidato a um ensaio **18 meses antes de ele ter sintomas** [5].

> *"O futuro da medicina não é tratar doenças — é tratar **trajetórias**."*
>
> Khera et al., JACC, 2024 [5]

MÓDULO 2 · IA EM RWE E PESQUISA CLÍNICA

Além do Óbvio

🪞 Digital Twins — Gêmeos Digitais

Réplicas virtuais de pacientes construídas a partir de dados de prontuário, imagem, laboratório e comportamento. Aplicação direta: **simular a resposta de um paciente a um protocolo antes de recrutá-lo** [6][7][8].

O FDA já reconhece digital twins como ferramenta para gerar registros clínicos simulados e prever resposta do grupo placebo. Projetos do FDA e EMA reconhecem digital twins como evidência complementar.

🧪 Controles Sintéticos (Synthetic Control Arms)

Substituto ou complemento ao braço controle em RCTs usando dados de RWD. **Reduz o N necessário, acelera o estudo e resolve problemas éticos de placebo em doenças graves** [9].

Exemplo real: O FDA aprovou cerliponase alfa para doença de Batten usando controles sintéticos em um estudo de braço único. O uso de controles externos e sintéticos pode reduzir significativamente o tamanho amostral e a exposição de pacientes ao placebo.

🔍 Recrutamento Preditivo

Modelos que cruzam dados de RWD (diagnósticos, prescrições, exames) com critérios de elegibilidade para rankear pacientes por probabilidade de qualificação e adesão.

98–100%
concordância com clínicos na triagem de elegibilidade (RECTIFIER, GPT-4)
Cunningham et al., JACC, 2024 [11]

US$0,10
custo por paciente triado vs. revisão manual tradicional
Cunningham et al., JACC, 2024 [11]

92%
dos pacientes oncológicos com ≥1 estudo relevante nas top 20 recomendações
Abdallah et al., Nat Commun, 2026 [12]

-41%
tempo de triagem (3,1 → 1,8 min/prontuário); 98.348 pacientes triados, 117 inscritos
Gong et al., JCO CCI, 2026 [13]

Plataformas como Watson for Clinical Trial Matching, Deep 6 AI e Mendel.AI demonstram alta sensibilidade e especificidade para identificação de elegibilidade e reduzem significativamente o tempo necessário para identificar pacientes elegíveis [10]. O sistema TrialMatchAI alcançou >90% de acurácia na classificação de elegibilidade por critério [12].

🔐 Federated Learning e Privacidade

Treinar modelos sem mover dados sensíveis. Estudos demonstram que **modelos federados entre 10 instituições alcançam 99% da qualidade de modelos com dados centralizados** [14]. Quando combinado com privacidade diferencial e SMPC, o federated learning **satisfaz os requisitos legais do GDPR** para pesquisa médica [15].

MÓDULO 3 · O ALICERCE

Garbage In, Garbage Out

"Qualquer modelo de IA é tão bom quanto os dados que o alimentam. E os dados clínicos são um caos." 80% dos dados clínicos estão em texto livre. Sem estruturação, nenhuma IA vai encontrar o paciente certo.

🏗️ OMOP-CDM
A Pedra de Roseta dos dados clínicos. **331 fontes, 2.1 bilhões de registros, 34 países.** 96–99% dos

🌐 SNOMED CT
10M+ conceitos, 136 vocabulários. "Infarto" em CID, texto livre e SNOMED são 3 coisas — SNOMED as unifica.

🤖 AI Scribe
LLMs com NER clínico transformam texto livre em **dados estruturados e consultáveis**.
[10][20]

registros mapeados com sucesso. [16][17][18]

[16][19]

A rede OHDSI é a maior rede de dados distribuídos do mundo, abrangendo mais de 331 fontes de dados com 2,1 bilhões de registros em 34 países [16]. A transformação para OMOP resulta em perda mínima de informação: 96–99% dos registros de condições e 90–99% dos registros de medicamentos são mapeados com sucesso [17]. Estudo australiano converteu dados de 2,03 milhões de pacientes ativos para OMOP com 97% de taxa de aprovação em avaliações de qualidade [18].

Sem OMOP, você não escala estudos multicêntricos. Com OMOP, você conecta a Hapvida a qualquer rede de pesquisa global.

A maioria dos dados clínicos relevantes está em texto livre — evolução médica, laudos, cartas de referência. LLMs com NER (Named Entity Recognition) clínico transformam esse ruído em dados estruturados e consultáveis [10][20].

MÓDULO 4 · LLMS EM RECRUTAMENTO CLÍNICO

Como o Mundo Está Fazendo

O pipeline que Stanford, NIH, MSKCC e Europa já validaram:

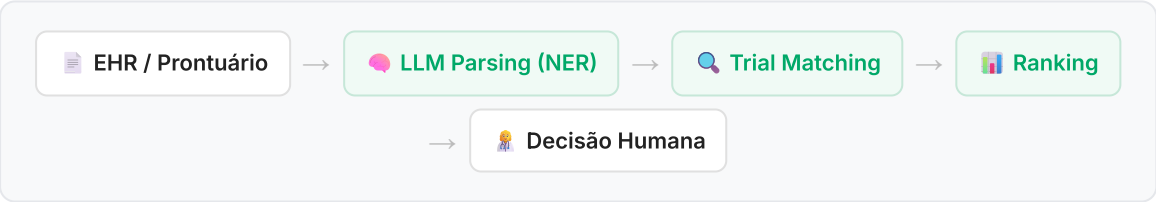

Evidências práticas:

- Sistema RECTIFIER (GPT-4): avaliou 23 critérios de elegibilidade com **98–100% de concordância** com clínicos, a um custo de **US$ 0,10 por paciente triado** [11].
- TrialMatchAI: alcançou **92% dos pacientes oncológicos com pelo menos um estudo relevante** nas top 20 recomendações, com **>90% de acurácia** na classificação por critério [12].
- Implementação em 29 estudos: triou **98.348 pacientes**, identificou **825 candidatos elegíveis**, facilitou **117 inscrições**, reduzindo a carga de revisão em **10×** e o tempo de triagem em **41%** (de 3,1 para 1,8 min/prontuário) [13].

HAPVIDA · PIPELINE EM AÇÃO

Como a Gente Faz

O pipeline da Hapvida opera em três fases integradas, de forma contínua:

🕐 02:00 AM — Coleta → 🔍 Match Determinístico → 🧠 IA Descreve →
📱 App Humano → 👩‍⚕️ Médico → 📞 Contato

Fase 1 — Automática (02:00 AM)

Todo dia às 2h da manhã, o sistema coleta automaticamente todas as consultas do dia anterior e pacientes de centros estratégicos com consultas nos próximos 7 dias. Realiza match determinístico com os critérios dos estudos ativos.

Fase 2 — Inteligente (IA)

Pacientes com match são reavaliados pela IA. Ela lê o prontuário completo, descreve e tenta explicar o match — ou contrapor — gerando um resumo de elegibilidade critério a critério.

- **Duplo sim (✓✓):** A IA confirma que o paciente preenche todos os critérios de inclusão e explica por quê. Esses pacientes são priorizados automaticamente.
- **Match parcial (✓✗):** A IA identifica critérios pendentes (ex.: resultado de PD-L1 não encontrado, biópsia pendente) e recomenda ações antes de confirmar elegibilidade.

Fase 3 — Humana

Recrutadores avaliam no app, priorizando pacientes com duplo sim. Médicos recebem o resumo da IA + avaliação do recrutador e confirmam ou rejeitam com justificativa clínica. Paciente é informado, consulta de screening agendada. **O ciclo recomeça todo dia às 2h.**

RESULTADOS · HAPVIDA

Os Números da Nossa Operação

170
pacientes elegíveis identificados em 2026

400+
pacientes aguardando resultado de exames

Maior base **OMOP** de saúde suplementar da América Latina. Cada exame que chega pode mudar o status de elegibilidade — em tempo real. Posicionamento da Hapvida como **plataforma de pesquisa**, não só operadora.

MÓDULO 5 · ALÉM DO RECRUTAMENTO

O Futuro Já Começou

Gêmeos Digitais

Réplicas virtuais de pacientes. O FDA já reconhece como evidência complementar. Simulam resposta antes de recrutar.

[6][7][8]

Controles Sintéticos

Substituir placebo com dados reais. Cerliponase alfa: aprovada pelo FDA sem placebo. Braço único. 100% RWD.

[9]

Federated Learning

Treinar modelos sem mover dados. 99% da qualidade de modelos centralizados. GDPR-compliant by design.

[14][15]

18 meses

O modelo preditivo de amanhã vai identificar um candidato a ensaio 18 meses antes dele ter sintomas [5]

FECHAMENTO

A Virada

> *"O próximo grande estudo clínico não vai ser atrasado por falta de pacientes. Vai ser acelerado por **dados que já existem** — e que finalmente sabemos usar."*

Victor Hugo Ovani Marchetti

Médico · Mestrando em Saúde Pública · LABDAPS/USP · Hapvida

victorovanimarchetti.com · LinkedIn

Referências

[1] Treweek S, Pitkethly M, Cook J, et al. **Strategies to Improve Recruitment to Randomised Trials.** *Cochrane Database Syst Rev.* 2018;2:MR000013. doi:10.1002/14651858.MR000013.pub6

[2] Houghton C, Dowling M, Meskell P, et al. **Factors That Impact on Recruitment to Randomised Trials in Health Care: A Qualitative Evidence Synthesis.** *Cochrane Database Syst Rev.* 2020;10:MR000045. doi:10.1002/14651858.MR000045.pub2

[3] Darden PM, Davis AM, Lee JY, et al. **Active vs Traditional Methods of Recruiting Children for a Clinical Trial in Rural Primary Care Clinics.** *JAMA Network Open.* 2022;5(11):e2244040. doi:10.1001/jamanetworkopen.2022.44040

[4] Brøgger-Mikkelsen M, Ali Z, Zibert JR, Andersen AD, Thomsen SF. **Online Patient Recruitment in Clinical Trials: Systematic Review and Meta-Analysis.** *J Med Internet Res.* 2020;22(11):e22179. doi:10.2196/22179

[5] Khera R, Oikonomou EK, Nadkarni GN, et al. **Transforming Cardiovascular Care With Artificial Intelligence: From Discovery to Practice.** *J Am Coll Cardiol.* 2024;84(1):97-114. doi:10.1016/j.jacc.2024.05.003

[6] Warraich HJ, Tazbaz T, Califf RM. **FDA Perspective on the Regulation of Artificial Intelligence in Health Care and Biomedicine.** *JAMA.* 2025;333(3):241-247. doi:10.1001/jama.2024.21451

[7] Moingeon P, Chenel M, Rousseau C, Voisin E, Guedj M. **Virtual Patients, Digital Twins and Causal Disease Models: Paving the Ground for in Silico Clinical Trials.** *Drug Discov Today.* 2023;28(7):103605. doi:10.1016/j.drudis.2023.103605

[8] Pammi M, Shah PS, Yang LK, et al. **Digital Twins, Synthetic Patient Data, and in-Silico Trials: Can They Empower Paediatric Clinical Trials?** *Lancet Digit Health.* 2025;7(5):100851. doi:10.1016/j.landig.2025.01.007

[9] Zannad F, Khan MS, Bansal N, et al. **MASLD, MASH, and the CKM Spectrum: A Roadmap for Multiorgan Clinical Trial Design.** *J Am Coll Cardiol.* 2026;:S0735-1097(25)10429-4. doi:10.1016/j.jacc.2025.12.015

[10] von Itzstein MS, Hullings M, Mayo H, et al. **Application of Information Technology to Clinical Trial Evaluation and Enrollment: A Review.** *JAMA Oncol.* 2021;7(10):1559-1566. doi:10.1001/jamaoncol.2021.1165

[11] Cunningham JW, Abraham WT, Bhatt AS, et al. **Artificial Intelligence in Cardiovascular Clinical Trials.** *J Am Coll Cardiol.* 2024;84(20):2051-2062. doi:10.1016/j.jacc.2024.08.069

[12] Abdallah M, Nakken S, Georges M, et al. **TrialMatchAI: An End-to-End AI-powered Clinical Trial Recommendation System.** *Nat Commun.* 2026;10.1038/s41467-026-70509-w.

doi:10.1038/s41467-026-70509-w

[13] Gong G, Liu J, Pandya S, et al. **Clinical Trial Patient Matching: A Real-Time, CDM and AI-Driven System for Semiautomated Prescreening.** *JCO Clin Cancer Inform.* 2026;10:e2500262.
doi:10.1200/CCI-25-00262

[14] Sheller MJ, Edwards B, Reina GA, et al. **Federated Learning in Medicine: Facilitating Multi-Institutional Collaborations Without Sharing Patient Data.** *Sci Rep.* 2020;10(1):12598.
doi:10.1038/s41598-020-69250-1

[15] Brauneck A, Schmalhorst L, Kazemi Majdabadi MM, et al. **Federated Machine Learning, Privacy-Enhancing Technologies, and Data Protection Laws in Medical Research.** *J Med Internet Res.* 2023;25:e41588.
doi:10.2196/41588

[16] Reich C, Ostropolets A, Ryan P, et al. **OHDSI Standardized Vocabularies — a Large-Scale Centralized Reference Ontology for International Data Harmonization.** *JAMIA.* 2024;31(3):583-590.
doi:10.1093/jamia/ocad247

[17] Voss EA, Makadia R, Matcho A, et al. **Feasibility and Utility of Applications of the Common Data Model to Multiple, Disparate Observational Health Databases.** *JAMIA.* 2015;22(3):553-64.
doi:10.1093/jamia/ocu023

[18] Ward R, Hallinan CM, Ormiston-Smith D, Chidgey C, Boyle D. **The OMOP Common Data Model in Australian Primary Care Data.** *PLoS One.* 2024;19(4):e0301557.
doi:10.1371/journal.pone.0301557

[19] Vashisht R, Jung K, Schuler A, et al. **Association of Hemoglobin A1c Levels With Use of Sulfonylureas, DPP-4 Inhibitors, and Thiazolidinediones in T2DM: Analysis From OHDSI.** *JAMA Network Open.* 2018;1(4):e181755.
doi:10.1001/jamanetworkopen.2018.1755

[20] Meystre SM, Heider PM, Cates A, et al. **Piloting an Automated Clinical Trial Eligibility Surveillance and Provider Alert System Based on AI and Standard Data Models.** *BMC Med Res Methodol.* 2023;23(1):88.
doi:10.1186/s12874-023-01916-6

Victor Hugo Ovani Marchetti
Médico · Mestrando em Saúde Pública · LABDAPS/USP · Hapvida
victorovanimarchetti.com · LinkedIn

Abril 2026 · Para salvar como PDF: Ctrl+P → Destino: Salvar como PDF